

Informe Ejecutivo

El presente informe resume el desarrollo, evaluación y selección de un modelo de probabilidad de default, incorporando análisis exploratorio, validación temporal y una política de aprobación orientada a maximizar la rentabilidad esperada.

Datos

Los datos abarcan solicitudes de crédito entre enero de 2024 y junio de 2025, provenientes del Data Warehouse corporativo separados en 2 archivos. Uno con 45.300 solicitudes con la finalidad de entrenar un modelo de ML que estime la probabilidad de incumplimiento crediticio y otro con 12.000 solicitudes para calcular la probabilidad del modelo entrenado. Además contienen información del perfil del solicitante, historial crediticio, comportamientos recientes del cliente, entre otras.

Hallazgos Exploratorios

Se realizó previamente una exploración general univariada y multivariada de los datos y se identificó cuatro hallazgos clave:

- **Inconsistencias de captura:** 10% de los ingresos declarados tenían valores menores a \$100.000, 70 solicitudes con edad fuera del rango válido [18,100] años, y 9 tasas de interés sobre la Tasa Máxima Convencional de la CMF publicada en la fecha de solicitud —, cuya corrección fue la mejora más determinante del proyecto.
- **Nulos estructurales:** para los campos `antiguedad_laboral_meses` (16%) e `ingreso_declarado` (18%), se tienen presencia de nulos debido a que previenen de los clientes con `tipo_empleo` informal y jubilado, es decir no es al azar. Se trataron con imputación condicional por grupo en vez de descartar registros o sesgar el promedio.
- **Posible fuga de información:** se sospecha que `num_contactos_ult_trimestre` es una variable contaminada con información posterior al desembolso, pues presenta fuertes indicios de correlación con la variable `target` de default de cumplimiento de 12 meses (correlación 0,73 con el resultado, $IV=4,52$, muy sobre el umbral de sospecha de 0,5), dando como consecuencia el epligro de inflar artificialmente el AUC sin ser replicables en producción.
- **Campo no confiable:** `dia_semana_solicitud`, 86% de inconsistencia con la fecha real), el cual se excluyó.

Además, se encontraron bajas presencia de multicolinealidad (VIF máximo 1,88).

Modelamiento

Se evaluaron tres familias de modelos de clasificación: **Regresión Logística**, **LightGBM** y **XGBoost**. Para cada una se desarrollaron seis rondas de modelamiento, donde en cada iteración se entrenaron múltiples configuraciones variando únicamente sus hiperparámetros. De esta forma, cada ronda permitió seleccionar la mejor versión de cada algoritmo bajo una estrategia específica de modelamiento. El entrenamiento se realizó utilizando solicitudes históricas de 2024, mientras que la evaluación se efectuó exclusivamente sobre solicitudes de enero y febrero de 2025, período nunca observado durante el entrenamiento. Esta partición temporal permitió simular un escenario de producción, donde el modelo debe predecir el comportamiento de clientes futuros.

La selección de los modelos se basó en dos criterios complementarios: capacidad de discriminación, medida mediante el AUC, y calibración de probabilidades, evaluada mediante el Brier Score. De esta forma se aseguró que el modelo no solo ordenara correctamente a los clientes según su riesgo, sino que también entregara probabilidades confiables para sustentar la política de aprobación.

Cada una de las seis rondas evaluó una hipótesis distinta de mejora.

Ronda	Qué se cambió	Razón
1	Datos tal cual llegaron, sin corregir errores	Modelo base
2	Se agregó el mes de la solicitud como variable adicional	Capturar estacionalidad
3	Se introdujeron datos sintéticos para robustecer el universo de clientes en default	Abordar desbalanceo
4	Se corrigieron los errores de captura encontrados en la exploración (edades imposibles, ingresos mal digitados, tasas de interés fuera de norma)	Mejorar la calidad de los datos de entrada
5	Se usó una ventana de tiempo distinta para entrenar y validar, más corta	Evaluar sensibilidad a la ventana de validación
6	Se entrenó solo con los últimos 6 meses de datos, en vez de con todo el historial disponible	Priorizar datos recientes sobre volumen histórico

Política de aprobación

Un modelo de probabilidad por sí solo no toma una decisión, ya que solo arroja una respuesta binaria. La forma de traducir la probabilidad mediante una aprobación o no de un crédito lo realizamos basado en la economía simplificada del producto, el cual define los siguientes umbrales (detalles en el anexo):

PLAZO (meses)	6	12	18	24	36	48
Umbral Rechazo (>=)	5,20%	9,80%	14,10%	17,90%	24,70%	30,40%

Resultados

Ronda	Modelo	Ventana validación	AUC	Brier	% aprobado	Ganancia con política	Pérdida evitada
1	Logística	ene-feb 2025	0,8337	0,0896	77,10%	\$404.680.600	\$444.081.000
1	LightGBM	ene-feb 2025	0,8307	0,0903			
1	XGBoost	ene-feb 2025	0,8349	0,0893	76,80%	\$405.026.700	\$442.079.000
2	Logística	ene-feb 2025	0,8338	0,0924	82,30%	\$382.467.200	\$390.247.000
2	LightGBM	ene-feb 2025	0,8319	0,0925			
2	XGBoost	ene-feb 2025	0,8342	0,0914	80,50%	\$400.856.500	\$415.569.000
3	Logística	ene-feb 2025	0,8339	0,0894	77,00%	\$407.584.300	\$451.060.500
3	LightGBM	ene-feb 2025	0,83	0,0901			
3	XGBoost	ene-feb 2025	0,8345	0,0893	76,80%	\$410.459.600	\$447.452.500
4	Logística	ene-feb 2025	0,835	0,0893	77,40%	\$406.006.500	\$445.692.500
4	LightGBM	ene-feb 2025	0,8315	0,0901			
4	XGBoost	ene-feb 2025	0,8352	0,0893	76,80%	\$405.750.900	\$443.250.500
5	Logística	jul-dic 2024 (n=20.426)	0,8504	0,0773	82,60%	\$2.104.211.000	\$1.383.899.000
5	LightGBM	jul-dic 2024 (n=20.426)	0,8414	0,0789			
5	XGBoost	jul-dic 2024 (n=20.426)	0,8475	0,0778	81,60%	\$2.085.026.700	\$1.392.303.000
6	Logística	ene-feb 2025	0,8344	0,0886	74,40%	\$419.944.400	\$479.215.000
6	LightGBM	ene-feb 2025	0,8268	0,0905			
6	XGBoost	ene-feb 2025	0,8325	0,0897	74,20%	\$422.311.800	\$479.369.000

Dentro de cada ronda, las tres familias de modelos rinden de forma casi idéntica (diferencias de AUC de pocas décimas de punto), confirmando que el algoritmo no es lo que determina la calidad del modelo en este problema — es la calidad de los datos. La Ronda 4 logra el mejor equilibrio entre las rondas comparables: el AUC más alto (0,835) junto con uno de los Brier score más bajos (0,089), y la mejor combinación de ganancia (\$406.006.500) y pérdida evitada (\$445.692.500) entre las alternativas válidas.

Las Rondas 2 y 6 se descartan: la Ronda 2 aprueba más solicitudes (82,3%) pero con probabilidades menos confiables (Brier más alto) y menor ganancia; la Ronda 6 —entrenada solo con los últimos 6 meses— rinde peor en AUC y Brier pese a mostrar una ganancia nominal algo mayor, lo que confirma que reducir el historial de entrenamiento no mejora el modelo. La Ronda 5 muestra las cifras más altas de la tabla (AUC 0,850, ganancia sobre \$2.000 millones), pero no es comparable con el resto: se validó contra un período distinto (jul-dic 2024) con casi 4 veces más solicitudes en el grupo de validación (n=20.426 vs. n=4.874), por lo que esas cifras no reflejan una mejora real del modelo, sino un examen distinto y más fácil.

Política de aprobación recomendada y ganancia estimada

Se recomienda implementar el modelo de regresión logística de la Ronda 4 junto con la política de aprobación por umbral de probabilidad, diferenciada según el plazo del crédito. Validada sobre las 4.874 solicitudes de enero-febrero 2025 —nunca vistas por el modelo durante el entrenamiento—, esta política aprueba el 77,4% de las solicitudes y genera \$406.006.500 de ganancia, evitando \$445.692.500 en pérdidas por default. Esto equivale a 5,3 veces más ganancia que la práctica implícita actual de aprobar todo, que en el mismo grupo generaría solo \$77.239.300.

Aplicando el mismo modelo y umbrales a las 12.000 solicitudes nuevas de test.csv, la ganancia esperada es de \$1.234.680.251.

Anexo

La regla: umbral de aprobación por plazo

Un modelo que solo entrega una probabilidad no decide nada por sí solo — hay que traducir esa probabilidad en un "sí" o un "no". La forma correcta de hacerlo no es un corte arbitrario (como 50%), sino comparar el **valor esperado de aprobar** contra la alternativa segura de **rechazar**.

La economía del producto (simplificada): si el cliente paga, la empresa gana aproximadamente el 6% del monto solicitado, prorrateado por el plazo ($\text{monto} \times 12\% \text{ anual} \times \text{plazo}/12 \times 0,5$, donde el factor 0,5 corrige porque el crédito se amortiza y el saldo pendiente promedio es la mitad del monto original). Si el cliente cae en default, la empresa pierde el 55% del monto (LGD).

La lógica del umbral: rechazar una solicitud siempre vale \$0 — no se gana ni se pierde. Aprobar es una apuesta: con probabilidad $(1-p)$ se gana la ganancia, con probabilidad p se pierde la pérdida. El valor esperado (EV) de esa apuesta es:

$$EV(\text{Aprobar}) = (1 - p) * \text{Ganancia} - p * \text{Pérdida}$$

La regla de decisión es simple: se aprueba solo si esa apuesta vale más que el \$0 seguro de rechazar, es decir, si $EV(\text{aprobar}) > 0$. El **umbral óptimo (p^*)** es exactamente el punto donde esa expresión es igual a cero — el punto de indiferencia entre aprobar y rechazar. Despejando:

$$p^* = \frac{\text{Ganancia}}{\text{Ganancia} + \text{Pérdida}}$$

Como la ganancia depende del plazo, pero la pérdida es un % fijo del monto, **el monto se cancela en la fórmula: el umbral no depende de cuánto pide el cliente, solo de a cuántos meses lo pide**. Créditos más largos generan más interés acumulado y toleran algo más de riesgo antes de que convenga rechazar:

PLAZO (meses)	6	12	18	24	36	48
Umbral Rechazo ($\geq$)	5,20%	9,80%	14,10%	17,90%	24,70%	30,40%